

EJERCICIO. OBTENCION DE DATOS DESDE LA WEB. OPEN DATA

SOLUCIÓN

Obtención de datos desde la web y portales Open Data

0. Cómo usar este documento

Este documento resuelve, de principio a fin, las dos partes del ejercicio, usando un ejemplo concreto en cada caso: la tabla de provincias españolas de Wikipedia (Parte 1) y un conjunto de datos del Catálogo Nacional de datos abiertos, datos.gob.es (Parte 2), con una mención adicional a NASA Open Data como alternativa resuelta con el mismo nivel de detalle.

Parte 1 (resuelta) · Tabla de provincias de España desde Wikipedia

Tabla elegida para este ejemplo

Usamos la Opción A propuesta en el enunciado: el artículo de Wikipedia “Anexo:Provincias y ciudades autónomas de España”, que recoge las 50 provincias españolas y las ciudades autónomas de Ceuta y Melilla, con su población, superficie, densidad y comunidad autónoma. Es una elección especialmente adecuada para este curso porque nos permite comparar estos datos oficiales con las seis provincias andaluzas de nuestro caso Comercial Sur Andalucía.

es.wikipedia.org/wiki/Anexo:Provincias_y_ciudades_autónomas_de_España

Paso a paso

1. Conectar con el conector Web

1. En Power BI Desktop, ve a Inicio > Obtener datos > Web.
2. Pega la URL completa del artículo de Wikipedia en el cuadro de diálogo y pulsa Aceptar.
3. Espera unos segundos mientras Power BI analiza el contenido HTML de la página.

2. Identificar la tabla correcta en el Navegador

Una página de Wikipedia como esta suele generar varias entradas en la ventana del Navegador: la tabla principal de provincias, pero también cuadros auxiliares (por ejemplo, un resumen de “Véase también”, tablas de artículos relacionados, o restos de plantillas de navegación). Para identificar la correcta:

- Haz clic en cada elemento de la lista izquierda y observa la vista previa de la derecha.
- Busca la tabla que tenga alrededor de 50-52 filas (una por provincia, más Ceuta y Melilla) y columnas como Provincia, Población, Superficie, Densidad y Comunidad autónoma.
- Es habitual que esta tabla aparezca nombrada de forma genérica como “Tabla 0”, “Tabla 1”, etc.: el nombre no es descriptivo, hay que fijarse en el contenido de la vista previa.

Idea clave: Este paso de “investigación visual” en el Navegador es, precisamente, la habilidad práctica más importante de todo el ejercicio: en el mundo real, ninguna fuente externa te va a decir de antemano cuál es la tabla correcta.

3. Limpiar la tabla en Power Query

1. Pulsa Transformar datos para abrir el editor de Power Query con la tabla seleccionada.
2. Revisa cada columna: las tablas de Wikipedia incorporan con frecuencia referencias numéricas entre corchetes (como [1]) pegadas al final de algunos valores, que conviene limpiar con Transformar > Reemplazar valores o Extraer > Texto antes del delimitador.
3. Elimina las columnas que no necesites para el análisis: por ejemplo, columnas de escudo o mapa (imágenes), o una columna de posición/ranking que no aporte valor si ya vas a ordenar por población dentro de Power BI.
4. Cambia el tipo de dato de la columna Población a Número entero, y el de Superficie y Densidad a Número decimal. Si Power Query no las reconoce automáticamente como número (por ejemplo, por llevar separador de miles con un formato distinto al esperado), utiliza Cambiar tipo con configuración regional..., seleccionando Español (España), tal y como practicamos en la sesión 3.
5. Renombra la columna de provincia como Provincia (en mayúscula inicial, sin espacios sobrantes) para mantener una nomenclatura consistente con el resto de tablas del curso.
6. Pulsa Inicio > Cerrar y aplicar para cargar la tabla ya limpia al modelo.

4. Crear un visual de comprobación

1. En la vista Informe, añade un gráfico de barras con Provincia en el eje y Población en los valores.
2. Ordena las barras de mayor a menor población y comprueba que el resultado tiene sentido (por ejemplo, Madrid o Barcelona deberían aparecer entre las provincias más pobladas).
3. Opcional: añade un filtro de visual limitado a las provincias andaluzas (Sevilla, Cádiz, Huelva, Córdoba, Málaga, Granada, Jaén y Almería) para comparar directamente con el universo de Comercial Sur Andalucía.

Respuestas de ejemplo a las preguntas de reflexión

Respuesta de ejemplo: Power BI detectó varias tablas en la página (entre 3 y 6, según el momento en que se consulte la página, ya que Wikipedia puede incluir tablas adicionales de artículos relacionados). Identifiqué la correcta por su número de filas (en torno a 50-52) y por el contenido de sus columnas en la vista previa (Provincia, Población, Superficie...).

Respuesta de ejemplo: Eliminé las columnas de escudo y mapa (imágenes, sin valor analítico en una tabla de Power BI) y una columna de posición/ranking redundante. Además, tuve que limpiar referencias numéricas entre corchetes pegadas a algunos valores de población.

Respuesta de ejemplo: Sí: la columna Población se cargó inicialmente como texto, porque el separador de miles de Wikipedia no coincidía con el que Power Query esperaba por defecto. Lo corregí usando "Cambiar tipo con configuración regional...", indicando Español (España).

Respuesta de ejemplo: Si la tabla de Wikipedia cambiara con el tiempo (por ejemplo, al publicarse nuevos datos de población), bastaría con pulsar Actualizar en Power BI Desktop:

como la conexión sigue viva a la URL original, Power Query repetiría automáticamente todos los pasos de limpieza sobre los datos nuevos, sin tener que rehacer el trabajo.

Parte 2 (resuelta) · Un conjunto de datos de datos.gob.es

Portal y conjunto de datos elegidos para este ejemplo

Usamos datos.gob.es, el Catálogo Nacional de datos abiertos del Gobierno de España, por ser el punto de entrada más general y estable: agrupa datasets de todas las administraciones públicas españolas (estatal, autonómica y local) en un único buscador, con indicación clara de la licencia y el formato de cada recurso.

[🔗 datos.gob.es/es/catalogo](https://datos.gob.es/es/catalogo)

Paso a paso

1. Buscar un conjunto de datos

1. Accede a datos.gob.es/es/catalogo.
2. Usa el buscador con un término relacionado con el negocio de Comercial Sur Andalucía, por ejemplo “turismo Andalucía”, “comercio” o “paro Andalucía”.
3. En los filtros laterales, limita los resultados por Formato (elige CSV o XLS/XLSX) y, si está disponible, por Cobertura geográfica o Tema, para acotar mejor la búsqueda.
4. Abre la ficha de un conjunto de datos que te resulte relevante. Revisa su descripción, el organismo que lo publica (por ejemplo, el propio INE, una consejería de la Junta de Andalucía, o un ayuntamiento), la frecuencia de actualización y la licencia de reutilización indicada.

2. Descargar el archivo

1. En la ficha del conjunto de datos, localiza la sección de Distribuciones o Recursos, donde se listan los archivos disponibles (a menudo en varios formatos: CSV, XLSX, JSON...).
2. Descarga el archivo en formato CSV o Excel, y guárdalo en tu carpeta Curso_PowerBI/Datos_Origen, siguiendo la nomenclatura de la sesión 1.

3. Conectar con Power BI Desktop

1. Abre un archivo nuevo en Power BI Desktop y guárdalo como Ejercicio_OpenData_TuNombre.pbix.
2. Ve a Obtener datos > Texto/CSV (o Excel, según el formato descargado) y selecciona el archivo.
3. En la ventana de vista previa, revisa el Delimitador (los archivos de organismos españoles suelen usar punto y coma) y el Origen del archivo (codificación UTF-8 o Windows-1252), corrigiéndolos si los acentos no se muestran correctamente, tal y como vimos en la sesión 2.

4. Limpiar y transformar

1. Pulsa Transformar datos para entrar en Power Query.
2. Es habitual que los archivos de organismos públicos incluyan una o varias filas de cabecera explicativa antes de la fila de encabezados real, o una fila de fuente/nota al final: usa Inicio > Reducir filas > Quitar filas superiores/inferiores para eliminarlas.

3. Usa Usar la primera fila como encabezados si el paso anterior ha dejado los nombres de columna reales en la primera fila visible.
4. Revisa y corrige el tipo de dato de cada columna, prestando especial atención a las columnas numéricas y de fecha, como practicamos en la sesión 3.
5. Renombra las columnas con nombres claros y consistentes si los originales son poco descriptivos (por ejemplo, códigos internos del organismo publicador).

5. Crear un visual de comprobación

1. Carga los datos y construye un visual sencillo (una tabla, un gráfico de barras o un mapa si el conjunto de datos incluye una columna geográfica) que resuma la información principal del conjunto de datos elegido.

Alternativa resuelta: NASA Open Data

Si prefieres un ejemplo con datos científicos en lugar de datos españoles, el catálogo de datasets de la NASA filtrado por formato CSV es un excelente punto de partida:

catalog.data.gov/dataset?res_format=CSV&organization=nasa-gov

El procedimiento es idéntico al descrito para datos.gob.es: buscar un dataset de interés (por ejemplo, sobre asteroides cercanos a la Tierra, actividad solar o exoplanetas), descargar su versión CSV, y conectarlo a Power BI mediante Obtener datos > Texto/CSV. Los archivos científicos de la NASA suelen venir en inglés y con nombres de columna técnicos (abreviaturas), por lo que renombrar columnas (paso 4.5 anterior) resulta especialmente útil en este caso.

Respuestas de ejemplo a las preguntas de reflexión

Respuesta de ejemplo: Elegí datos.gob.es y busqué un conjunto de datos sobre turismo o comercio en Andalucía, por su conexión directa con el caso Comercial Sur Andalucía del curso: me pareció interesante poder comparar, en el futuro, los datos internos de la empresa con el contexto general del sector en la región.

Respuesta de ejemplo: La ficha del conjunto de datos indicaba una licencia de reutilización abierta (habitualmente basada en Creative Commons o en la propia normativa española de reutilización de la información del sector público), que permite el uso comercial y no comercial citando la fuente.

Respuesta de ejemplo: La tabla web de Wikipedia (Parte 1) se conecta directamente a una URL y Power BI la interpreta automáticamente como una tabla; el archivo de Open Data (Parte 2) hay que descargarlo antes a nuestro equipo y luego conectarlo como un archivo local, lo que en la práctica desconecta el archivo Power BI de cualquier cambio futuro en el portal, salvo que se vuelva a descargar y sustituir manualmente.

Respuesta de ejemplo: Fueron necesarias, al menos, dos transformaciones: quitar una fila de cabecera explicativa que no formaba parte de los datos reales, y corregir el tipo de dato de una columna numérica que se había cargado como texto por el separador decimal.

Respuesta de ejemplo: Usaría el campo Provincia (o, si el conjunto de datos lo detalla más, Código de provincia del INE) como clave común, de la misma forma que en la sesión 5

relacionamos Ventas con Clientes a través de Codigo_Cliente: un campo compartido entre ambas tablas permitiría relacionar las ventas internas con el contexto sectorial de cada provincia.

Errores habituales al resolver este ejercicio

Cargar la tabla equivocada de Wikipedia

Cargar la primera tabla que aparece en el Navegador sin comprobar su contenido es el error más frecuente: revisa siempre la vista previa antes de confirmar.

No revisar la licencia de los datos abiertos

Aunque el Open Data está pensado precisamente para reutilizarse, cada portal (y a veces cada dataset) puede tener condiciones ligeramente distintas: acostumbrarse a comprobar la licencia es una buena práctica profesional, más allá de este ejercicio.

Olvidar limpiar las referencias de Wikipedia

Los corchetes de referencia bibliográfica ([1], [n. 3]...) pegados a un valor numérico son una causa muy habitual de que una columna se cargue como texto en lugar de como número.

No comprobar la codificación de caracteres en archivos de organismos españoles

Es frecuente encontrar archivos CSV de administraciones públicas codificados en Windows-1252 en lugar de UTF-8: si ves símbolos extraños en las tildes, revisa el Origen del archivo al conectar, como se explicó en la sesión 2.

Para ir más allá: Una vez completado este ejercicio, prueba a repetir la Parte 2 con un portal distinto (por ejemplo, la Junta de Andalucía o Eurostat) y compara qué tan fácil o difícil resulta encontrar y descargar un conjunto de datos en cada uno: no todos los portales de Open Data están igual de bien organizados.